

Fundamentos de Machine Learning


Comitês de Modelos

Aula 1.1 Medindo erros Prof. Pedro Calais






Lembra da árvore de decisão?





- Fácil de construir
- Fácil de usar
- Fácil de interpretar





Problema: árvores de decisão são instáveis

Instability of Decision Tree Classification Algorithms


Ruey-Hsia Li Lightspeed Semiconductor 209 N. Fair Oaks Avenue Sunnyvale, CA 94085 rli@lightspeed.com Geneva G. Belford

Department of Computer Science
University of Illinois at Urbana-Champaign
Urbana, IL 61801

belford@cs.uiuc.edu




Um pequeno conjunto de dados






E se o registro #2 for diferente?






Mais um exemplo







Introduzindo uma pequena mudança




<u>Fundamentos de Machine Learning</u>





Árvores de decisão têm alta variância


- Pequenas mudanças nos dados ou nos hiperparâmetros
- → Modelos muito diferentes





Contraponto

 Regressão linear tende a ter baixa variância






Árvores de decisão têm alta variância



Decision Trees Have a High Variance

More generally, the main issue with decision trees is that they have quite a high variance: small changes to the hyperparameters or to the data may produce very different models. In fact, since the training algorithm used by Scikit-Learn is stochastic—it randomly selects the set of features to evaluate at each node—even retraining the same decision tree on the exact same data may produce a very different model, such as the one represented in Figure 6-9 (unless you set the random_state hyperparameter). As you can see, it looks very different from the previous decision tree (Figure 6-2).





Por que alta variância é um problema?

- Imprevisibilidade
- Aprendendo o ruído
- Treina o modelo várias vezes, resultados muito diferentes
- Difícil validar
- Modelo está se ajustando em excesso?






Como reduzir a variância de árvores de decisão?





Como reduzir a variância de árvores de decisão?


- Gere várias árvores
- Tire a média das previsões





As árvores precisam ser diferentes, certo?

- Selecione os registros aleatoriamente
- Selecione colunas aleatoriamente






Aleatorize os registros

id	x_0	x_1	x_2	x_3	x_4	y	id	id	id	$i\epsilon$
0	4.3	4.9	4.1	4.7	5.5	0	2	2	4	3
1	3.9	6.1	5.9	5.5	5.9	-0.	0	1	. 1	3
2	2.7	4.8	4.1	5.0	5.6	0	2	3	3	2
3	6.6	4.4	4.5	3.9	5.9	1	4	1	0	- 5
4	6.5	2.9	4.7	4.6	6.1	1	5	4	0	1
5	2.7	6.7	4.2	5.3	4.8	1	5	4	2	2






Aleatorize os atributos




























Como fazer uma previsão?



Fundamentos de Machine Learning



Como fazer uma previsão?




Fundamentos de Machine Learning



Por que a floresta tende a diminuir a variância?


- Várias árvores diminuem a sensibilidade a registros e colunas específicas
- Menos overfitting!





Por que a floresta tende a diminuir a variância?


Fraquezas individuais de cada árvore tendem a se anular





Conclusão


Bem-vindo às random forests:-)






Os tipos de aprendizado de máquina

3 Types of Machine Learning (Every Data Scientist Should Know)





Como a máquina se confunde?





Modelos e fronteiras de decisão





